

## AZURE DATA FACTORY LINKS



## DISEÑO DEL ORIGEN Y ALMACENAMIENTO DE DATOS

La arquitectura propuesta parte de una situación en la que una empresa recibe diariamente archivos CSV que contienen información relacionada con ventas realizadas durante la jornada.

Estos archivos representan la fuente inicial de datos dentro del proceso de integración y análisis, por lo que resulta necesario diseñar una estrategia de almacenamiento que permita organizar correctamente la información antes de iniciar cualquier proceso de transformación posterior.

Para ello se ha seleccionado Azure Blob Storage como servicio principal de almacenamiento cloud. Este servicio permite gestionar grandes volúmenes de información no estructurada, facilitando el almacenamiento de archivos planos como CSV, JSON, logs o cualquier otro formato utilizado como fuente inicial de datos.

Los archivos recibidos diariamente serán almacenados dentro del Blob Storage siguiendo una estructura jerárquica organizada cronológicamente.

La empresa recibe **archivos CSV diarios de ventas**.

Ejemplo:

Cada día llega un archivo:


ventas\_2026\_07\_01.csv  
ventas\_2026\_07\_02.csv  
ventas\_2026\_07\_03.csv

Cada CSV podría tener:

| Order_ID | Product | Units | Price | Date       |
|----------|---------|-------|-------|------------|
| 1001     | Shoes   | 2     | 80    | 01/07/2026 |
| 1002     | Jacket  | 1     | 120   | 01/07/2026 |

El objetivo NO es dejar todos los archivos tirados en una carpeta, hay que organizarlo como haría una empresa real.


La estructura propuesta es la siguiente:



La estructura propuesta es la siguiente:



Ejemplo práctico:



La decisión de organizar los archivos siguiendo una estructura temporal responde a varios criterios técnicos.

En primer lugar, facilita la localización rápida de archivos históricos cuando se requiere acceder a datos concretos correspondientes a fechas determinadas.

En segundo lugar, permite automatizar procesos de lectura dentro de Azure Data Factory, ya que los pipelines pueden configurarse para detectar automáticamente nuevos archivos dentro de rutas específicas.

Además, esta estructura facilita la escalabilidad del sistema, permitiendo almacenar grandes volúmenes de información sin comprometer la organización general del entorno.

Finalmente, el uso de Azure Blob Storage garantiza una integración nativa con otros servicios del ecosistema Azure, especialmente con Azure Data Factory, herramienta que será utilizada en fases posteriores para la ingesta y transformación de los datos almacenados.

## **DISEÑO DEL FLUJO DE DATOS Y TRANSFORMACIONES**

Una vez almacenados los archivos CSV dentro del entorno cloud, el siguiente paso dentro de la arquitectura consiste en diseñar el flujo de procesamiento encargado de leer, transformar y preparar los datos para su posterior análisis.

Para ello se utiliza Azure Data Factory, servicio encargado de ejecutar procesos ETL dentro del ecosistema Azure.

El flujo de datos diseñado se compone de varias etapas consecutivas.

La primera etapa corresponde a la **ingesta de datos**, donde Azure Data Factory accede a los archivos CSV previamente almacenados dentro de Azure Blob Storage mediante la configuración de un Dataset de entrada.

Una vez leídos los datos, se inicia la fase de transformación.


La primera transformación seleccionada consiste en **eliminar registros que contienen valores nulos o incompletos**, evitando que información errónea afecte al análisis posterior.

Posteriormente se aplica una segunda transformación orientada a **normalizar el formato de fechas**, unificando todos los registros bajo un formato estándar YYYY-MM-DD.

Tras finalizar las transformaciones, Azure Data Factory genera un nuevo Dataset de salida que contiene los datos ya procesados.

Finalmente, los resultados son almacenados utilizando formato Apache Parquet, elegido por sus ventajas en eficiencia de almacenamiento, compresión y velocidad de lectura dentro de arquitecturas cloud orientadas al análisis de datos.

La secuencia completa del flujo permite transformar archivos sin procesar en datos limpios, estructurados y preparados para etapas posteriores de análisis y visualización.



## **DISEÑO DEL PIPELINE**

Una vez definido el flujo de transformación de datos, resulta necesario automatizar su ejecución mediante un Pipeline dentro de Azure Data Factory.

El Pipeline actúa como elemento de orquestación, permitiendo ejecutar automáticamente todas las tareas definidas dentro del proceso ETL.


En primer lugar, se configura un Trigger programado diariamente, encargado de iniciar automáticamente la ejecución del proceso.

Una vez activado, el Pipeline accede a los archivos CSV almacenados en Azure Blob Storage.

Posteriormente, se ejecuta el Data Flow, donde se aplican las transformaciones previamente diseñadas, incluyendo eliminación de valores nulos y normalización del formato de fechas.

Una vez procesados, los datos transformados son almacenados automáticamente para su análisis posterior.

La automatización mediante Pipeline permite mantener la información constantemente actualizada, reduciendo intervención manual y garantizando disponibilidad casi en tiempo real para procesos analíticos y toma de decisiones.



## **ALMACENAMIENTO DE RESULTADOS E INTEGRACIÓN CON POWER BI**

Una vez finalizado el proceso de transformación, los datos procesados son almacenados nuevamente en Azure Blob Storage dentro de una zona específica destinada a información ya procesada.


Los resultados se almacenan en formato Apache Parquet, optimizado para entornos cloud debido a su capacidad de compresión, velocidad de lectura y eficiencia en procesos analíticos.


Posteriormente, estos datos son conectados con Microsoft Power BI mediante una conexión directa al almacenamiento cloud.

Power BI accede a los archivos procesados e incorpora la información dentro del modelo analítico.

A continuación, se configura un proceso de actualización automática (*data refresh*), permitiendo que cada vez que Azure Data Factory procese nuevos datos, el dashboard refleje la información más actualizada disponible.

Finalmente, los usuarios pueden acceder a dashboards interactivos que permiten analizar ventas, identificar tendencias y facilitar la toma de decisiones basada en información prácticamente en tiempo real.





La arquitectura diseñada representa un flujo completo de procesamiento de datos dentro del ecosistema cloud de Microsoft Azure, permitiendo automatizar la ingesta, transformación, almacenamiento y análisis de información de ventas recibida diariamente mediante archivos CSV.

El proceso comienza con la recepción de archivos CSV que son almacenados en Azure Blob Storage como repositorio inicial de datos. Posteriormente, Azure Data Factory accede a dichos archivos y ejecuta un flujo de transformación donde se eliminan registros incompletos y se normaliza el formato de fechas.

Una vez procesados, los datos son almacenados en formato Apache Parquet, optimizando almacenamiento y rendimiento. A continuación, un Pipeline automatizado permite ejecutar diariamente todo el proceso sin intervención manual, garantizando información actualizada.

Finalmente, Microsoft Power BI consume los datos procesados para generar dashboards interactivos que permiten analizar información en tiempo casi real y facilitar la toma de decisiones basada en datos.

## CONCLUSIÓN DE LA ARQUITECTURA

La solución propuesta integra un proceso ETL completo en entorno cloud, permitiendo automatizar la captura, transformación, almacenamiento y visualización de datos de forma escalable y eficiente.

La combinación de Azure Blob Storage, Azure Data Factory, procesamiento en formato Parquet y visualización mediante Power BI permite construir una arquitectura moderna orientada a analítica avanzada y disponibilidad continua de información actualizada.

Este modelo garantiza automatización, optimización del almacenamiento, reducción de tareas manuales y disponibilidad de dashboards dinámicos que facilitan la toma de decisiones empresariales basadas en datos en tiempo real.



